

ورود به دنیای هوش مصنوعی

دوره‌ی مقدماتی و رایگان برای عموم علاقه‌مندان

جلسه‌ی پنجم: دسته‌بندی، درخت تصمیم و نزدیک‌ترین همسایه‌ها

علی شریفی زارچی

رئیس کمیته‌ی علمی بین‌المللی المپیاد جهانی هوش مصنوعی

عضو کمیته‌ی علمی بین‌المللی المپیاد جهانی کامپیوتر

مرور جلسه‌ی قبل

- پیش‌بینی برچسب پیوسته: رگرسیون (Regression)
- تابع هزینه (Cost Function): معیار فاصله‌ی پیش‌بینی با واقعیت
- گرادیان کاهشی: کوه‌نوردی در مه، قدم‌به‌قدم به سمت کمترین خطا
- نرخ یادگیری (Learning Rate): طول گام‌های کوه‌نورد
- ظرفیت مدل، کم‌برازش (Underfitting) و بیش‌برازش (Overfitting)
- تمرین عملی: پیش‌بینی قیمت خانه‌های تهران با scikit-learn

سوال کلیدی

تا امروز یک «عدد» را پیش‌بینی کردیم؛
اگر پاسخ، یک «دسته» باشد چه؟

زنده ماند یا نماند؟ اسپم یا غیراسپم؟ سالم یا بیمار؟

دسته‌بندی در دنیای واقعی

پزشکی

آیا این بیمار مبتلاست؟
سالم / بیمار

ایمیل

آیا این ایمیل اسپم است؟
اسپم / غیراسپم

تایتانیک

آیا این مسافر زنده می‌ماند؟
زنده ماند / زنده نماند
مثال محوری امروز

خروجی مدل به‌جای یک عدد پیوسته، یک برچسب گسسته است.

آشنایی با دیتاست تایتانیک

برچسب (Label): Survived

- ۱ = زنده ماند
- ۰ = زنده نماند
- معروف‌ترین دیتاست آموزشی دنیا

ویژگی‌ها (Features)

- جنسیت، سن، کلاس بلیت (۱ تا ۳)
- کرایه، بندر سوارشدن، تعداد همراهان
- اطلاعات واقعی ۸۹۱ مسافر (سال ۱۹۱۲)

همان الگوی آشنا: از روی ویژگی‌ها، برچسب را پیش‌بینی کن.

آیا الگویی در داده هست؟

کلاس ۱ بلیت: ۶۳%

بقای کلاس ۱ برابر ۶۳%

کلاس ۳ تنها ۲۴%

زنان: ۷۴%

بقای زنان ۷۴%

بقای مردان تنها ۱۹%

کل مسافران: ۳۸%

از هر ۱۰۰ مسافر، تنها ۳۸ نفر


زنده ماندند.

«زن و بچه‌ها اول!» — الگو در داده هست؛ مدل باید آن را کشف کند.

درخت تصمیم: بازی بیست سوالی

- در بیست سوالی، با چند سوال بله/خیر هوشمندانه به جواب می‌رسید
- درخت تصمیم همین کار را می‌کند: از داده سوال می‌پرسد و بر اساس پاسخ، شاخه‌شاخه پیش می‌رود
- هر مسافر از ریشه‌ی درخت شروع می‌کند و به یک «برگ» می‌رسد؛ برگ همان پیش‌بینی است
- قدرت درخت در انتخاب «سوال‌های خوب» است
- نکته: درخت تصمیم با گرادیان کاهشی آموزش نمی‌بیند – کوه‌نورد ما این جلسه استراحت می‌کند!

یک درخت تصمیم روی تایتانیک



درصدهای بقا از داده‌ی واقعی تایتانیک؛ درخت با دو-سه سوال ساده به پیش‌بینی خوبی می‌رسد و کاملاً قابل توضیح است.

ماشین چطور بهترین سوال را پیدا می‌کند؟

سوال خوب، داده را به گروه‌های «خالص‌تر» تقسیم می‌کند؛ گروه‌هایی که تکلیفشان روشن‌تر است.

تقسیم با «بندر» – سوال ضعیف

شربورگ ۵۵٪، کوئینزتاون ۳۹٪، ساوت‌همپتون ۳۴٪
گروه‌ها هنوز مخلوط و نامطمئن‌اند
خلوص چندانی به دست نیامد

تقسیم با «جنسیت» – سوال خوب

زنان: ۷۴٪ بقا: گروه تقریباً یک‌دست
مردان: ۱۹٪ بقا: گروه تقریباً یک‌دست
هر دو گروه از ۳۸٪ اولیه «خالص‌تر» شدند

درخت در هر مرحله همه‌ی سوال‌های ممکن را امتحان می‌کند و خالص‌کننده‌ترین را برمی‌گزیند.

عمق درخت: همان ظرفیت مدل!

عمق بسیار کم

فقط یک سوال: «زن است؟»
الگوهای مهم را نمی بیند:
کم برآزش (Underfitting)

عمق مناسب

چند سوال هوشمندانه؛
الگوهای واقعی را یاد می گیرد و روی
مسافران جدید خوب جواب می دهد.

عمق بسیار زیاد

برای هر مسافر یک شاخه ی اختصاصی!
حفظ کردن به جای یادگیری:
بیش برآزش (Overfitting)

عمق درخت یک ابرپارامتر است. بهترین مقدار را با داده ی اعتبارسنجی (Validation) پیدا می کنیم.