

ورود به دنیای هوش مصنوعی

دوره‌ی مقدماتی و رایگان برای عموم علاقه‌مندان

جلسه‌ی پنجم: دسته‌بندی، درخت تصمیم و نزدیک‌ترین همسایه‌ها

علی شریفی زارچی

رئیس کمیته‌ی علمی بین‌المللی المپیاد جهانی هوش مصنوعی

عضو کمیته‌ی علمی بین‌المللی المپیاد جهانی کامپیوتر

مرور جلسه‌ی قبل

- پیش‌بینی برچسب پیوسته: رگرسیون (Regression)
- تابع هزینه (Cost Function): معیار فاصله‌ی پیش‌بینی با واقعیت
- گرادیان کاهشی: کوه‌نوردی در مه، قدم‌به‌قدم به سمت کمترین خطا
- نرخ یادگیری (Learning Rate): طول گام‌های کوه‌نورد
- ظرفیت مدل، کم‌برازش (Underfitting) و بیش‌برازش (Overfitting)
- تمرین عملی: پیش‌بینی قیمت خانه‌های تهران با scikit-learn

سوال کلیدی

تا امروز یک «عدد» را پیش‌بینی کردیم؛
اگر پاسخ، یک «دسته» باشد چه؟

زنده ماند یا نماند؟ اسپم یا غیراسپم؟ سالم یا بیمار؟

دسته‌بندی در دنیای واقعی

پزشکی

آیا این بیمار مبتلاست؟
سالم / بیمار

ایمیل

آیا این ایمیل اسپم است؟
اسپم / غیراسپم

تایتانیک

آیا این مسافر زنده می‌ماند؟
زنده ماند / زنده نماند
مثال محوری امروز

خروجی مدل به‌جای یک عدد پیوسته، یک برچسب گسسته است.

آشنایی با دیتاست تایتانیک

برچسب (Label): Survived

- ۱ = زنده ماند
- ۰ = زنده نماند
- معروف‌ترین دیتاست آموزشی دنیا

ویژگی‌ها (Features)

- جنسیت، سن، کلاس بلیت (۱ تا ۳)
- کرایه، بندر سوارشدن، تعداد همراهان
- اطلاعات واقعی ۸۹۱ مسافر (سال ۱۹۱۲)

همان الگوی آشنا: از روی ویژگی‌ها، برچسب را پیش‌بینی کن.

آیا الگویی در داده هست؟

کلاس ۱ بلیت: ۶۳%

بقای کلاس ۱ برابر ۶۳%

کلاس ۳ تنها ۲۴%

زنان: ۷۴%

بقای زنان ۷۴%

بقای مردان تنها ۱۹%

کل مسافران: ۳۸%

از هر ۱۰۰ مسافر، تنها ۳۸ نفر


زنده ماندند.

«زن و بچه‌ها اول!» — الگو در داده هست؛ مدل باید آن را کشف کند.

درخت تصمیم: بازی بیست سوالی

- در بیست سوالی، با چند سوال بله/خیر هوشمندانه به جواب می‌رسید
- درخت تصمیم همین کار را می‌کند: از داده سوال می‌پرسد و بر اساس پاسخ، شاخه‌شاخه پیش می‌رود
- هر مسافر از ریشه‌ی درخت شروع می‌کند و به یک «برگ» می‌رسد؛ برگ همان پیش‌بینی است
- قدرت درخت در انتخاب «سوال‌های خوب» است
- نکته: درخت تصمیم با گرادیان کاهشی آموزش نمی‌بیند – کوه‌نورد ما این جلسه استراحت می‌کند!

یک درخت تصمیم روی تایتانیک



درصدهای بقا از داده‌ی واقعی تایتانیک؛ درخت با دو-سه سوال ساده به پیش‌بینی خوبی می‌رسد و کاملاً قابل توضیح است.

ماشین چطور بهترین سوال را پیدا می‌کند؟

سوال خوب، داده را به گروه‌های «خالص‌تر» تقسیم می‌کند؛ گروه‌هایی که تکلیفشان روشن‌تر است.

تقسیم با «بندر» – سوال ضعیف

شربورگ ۵۵٪، کوئینزتاون ۳۹٪، ساوت‌همپتون ۳۴٪
گروه‌ها هنوز مخلوط و نامطمئن‌اند
خلوص چندانی به دست نیامد

تقسیم با «جنسیت» – سوال خوب

زنان: ۷۴٪ بقا: گروه تقریباً یک‌دست
مردان: ۱۹٪ بقا: گروه تقریباً یک‌دست
هر دو گروه از ۳۸٪ اولیه «خالص‌تر» شدند

درخت در هر مرحله همه‌ی سوال‌های ممکن را امتحان می‌کند و خالص‌کننده‌ترین را برمی‌گزیند.

عمق درخت: همان ظرفیت مدل!

عمق بسیار کم

فقط یک سوال: «زن است؟»
الگوهای مهم را نمی بیند:
کم برآزش (Underfitting)

عمق مناسب

چند سوال هوشمندانه؛
الگوهای واقعی را یاد می گیرد و روی
مسافران جدید خوب جواب می دهد.

عمق بسیار زیاد

برای هر مسافر یک شاخه ی اختصاصی!
حفظ کردن به جای یادگیری:
بیش برآزش (Overfitting)

عمق درخت یک ابرپارامتر است. بهترین مقدار را با داده ی اعتبارسنجی (Validation) پیدا می کنیم.

نزدیک‌ترین همسایه‌ها (KNN)

- «به من بگو شبیه چه کسانی هستی، تا بگویم چه سرنوشتی داری.»
- برای مسافر جدید، K مسافر شبیه به او را در داده‌ها پیدا کن (هم‌سن، هم‌کلاس، هم‌کرایه، ...)
- بین K همسایه رای‌گیری کن؛ رای اکثریت، پیش‌بینی مدل است
- مثال با $K=5$: خانم ۲۸ ساله‌ی کلاس ۲ → از ۵ مسافر شبیه او، ۴ نفر زنده مانده‌اند → زنده می‌ماند
- مرحله‌ی آموزش ندارد؛ فقط داده‌ها را نگه می‌دارد و هنگام پیش‌بینی، فاصله‌ها را می‌سنجد KNN

نقش K: چند همسایه بپرسیم؟

K بسیار بزرگ

رای‌گیری از کل کشتی!
همه یک پیش‌بینی یکسان می‌گیرند:
کم‌برازش

K مناسب

رای‌گیری از جمعی معقول؛
نویز حذف می‌شود و الگوی
محلی حفظ می‌شود.

K = ۱

فقط نزدیک‌ترین نفر!
حساس به نویز و استثناها:
بیش‌برازش

K هم یک ابرپارامتر است و می‌توانیم مقدار بهینه‌ی آن را با داده‌های Validation مشخص کنیم.

دام مقیاس: فاصله را چه کسی تعیین می‌کند؟

- سن مسافران بین ۰ تا ۸۰ است؛ کرایه‌ی بلیت بین ۰ تا ۵۱۲ پوند
- در محاسبه‌ی فاصله، ۳۰ سال اختلاف سن و ۳۰ پوند اختلاف کرایه یک‌اندازه اثر دارند!
- ویژگی با اعداد بزرگ‌تر، فاصله را می‌بلعد و بقیه‌ی ویژگی‌ها عملاً نادیده گرفته می‌شوند
- راه‌حل: هم‌مقیاس‌سازی (Scaling) – همه‌ی ویژگی‌ها به بازه‌ی مشابه، مثلاً ۰ تا ۱
- درخت تصمیم به مقیاس حساس نیست، اما KNN حتماً به Scaling نیاز دارد

درخت تصمیم در برابر KNN

نزدیک‌ترین همسایه‌ها

بدون مرحله‌ی آموزش؛ ولی پیش‌بینی کند
حتما به هم‌مقیاس‌سازی نیاز دارد
خطر بیش‌برازش با K کوچک

درخت تصمیم

کاملا قابل توضیح: می‌توان درخت را «خواند»
به مقیاس ویژگی‌ها حساس نیست
خطر بیش‌برازش با عمق زیاد

دو نگاه متفاوت به یک مسئله؛ در نوت‌بوک هر دو را روی تایتانیک می‌سنجیم.

سوال کلیدی

مدل ساختیم و پیش‌بینی کرد؛
از کجا بفهمیم واقعا خوب است؟

ماتریس درهم‌ریختگی (Confusion Matrix)

پیش‌بینی مدل روی ۱۰۰ مسافر داده‌ی تست – کلاس مثبت: «زنده ماند»

پیش‌بینی: زنده نماند

۹

منفی نادرست (FN)
زنده‌مانده‌ای که از قلم افتاد

پیش‌بینی: زنده ماند

۲۵

مثبت درست (TP)
گفت «زنده ماند» و درست بود

واقعیت: زنده ماند

۵۸

منفی درست (TN)
گفت «زنده نماند» و درست بود

۸

مثبت نادرست (FP)
هشدار اشتباه «زنده ماند»

واقعیت: زنده نماند

دقت = $(۲۵+۵۸) / ۱۰۰ = ۸۳\%$

اما دو نوع خطای FP و FN هم‌ارزش نیستند؛ بسته به مسئله، یکی زیان‌بارتر است!

فریبِ دقت (Accuracy)

بیماری نادر: دقت ۹۹.۹٪

بیماری ۱ در ۱۰۰۰ نفر؛ همه را «سالم» اعلام کن!
دقت ۹۹.۹٪ می‌شود، اما حتی
یک بیمار واقعی هم پیدا نمی‌شود.

مدل تنبل تایتانیک: دقت ۶۲٪

برای همه بگو «زنده نماند»!
چون ۶۲٪ مسافران واقعا زنده نماندند،
بدون هیچ هوشی ۶۲٪ دقت می‌گیرد.

دقت به‌تنهایی کافی نیست؛ باید ببینیم مدل «کجا» اشتباه می‌کند.

پوشش (Recall): چند مورد واقعی را پیدا کردیم؟

کجا حیاتی است؟

وقتی جابماندن زیان بار است:
غریبالگری سرطان! حتی یک بیمار واقعی
نباید از قلم بیفتد.

$$\text{Recall} = \text{TP} \div (\text{TP} + \text{FN})$$

از زنده ماندن های واقعی، چند درصد پیدا شدند؟
 $25 \div (25 + 9) \approx 74\%$
پوشش بالا یعنی جابمانده (FN) کم است

صحت (Precision): چقدر حرف مدل قابل اعتماد است؟

کجا حیاتی است؟

وقتی هشدار اشتباه زیان بار است:
• فیلتر اسپم! ایمیل مهم کاری
• هرگز نباید اسپم اعلام شود.

$$\text{Precision} = \text{TP} \div (\text{TP} + \text{FP})$$

از پیش‌بینی‌های «زنده ماند»، چند درصد درست بود؟
 $25 \div (25 + 8) \approx 76\%$
صحت بالا یعنی هشدار اشتباه (FP) کم است

بدهستان صحت و پوشش

این دو معمولا با هم بالا نمی‌روند؛ سخت‌گیری بیشتر یعنی صحت بالاتر ولی پوشش کمتر – و برعکس.

غریبال‌گری سرطان: پوشش (Recall) مهم‌تر

با کوچک‌ترین شک بگو «مشکوک»؛
آزمایش تکمیلی، هشدار اشتباه را رفع می‌کند.
هزینه‌ی FN بالاست.

فیلتر اسپم: صحت (Precision) مهم‌تر

فقط وقتی کاملا مطمئنی بگو «اسپم»،
حتی اگر چند اسپم از دستمان فرار کنند؛
هزینه‌ی FP بالاست.

معیار مناسب را «مسئله» تعیین می‌کند، نه ریاضیات!

معیار F1: آشتی‌دهنده‌ی صحت و پوشش

چرا میانگین هارمونیک؟

اگر یکی از دو معیار خیلی پایین باشد هم سقوط می‌کند
نمی‌شود ضعف یکی را
با قوت دیگری پنهان کرد.

$$F1 = 2 \times (P \times R) \div (P + R)$$

یک عدد واحد که هر دو معیار را جدی می‌گیرد
 $2 \times (0.76 \times 0.74) \div (0.76 + 0.74) \approx 75\%$
میانگین هارمونیک است، نه معمولی

قانون طلایی: همه‌ی معیارها را روی داده‌های ارزیابی و تست حساب می‌کنیم، نه داده‌ی آموزش!

قدم بعدی: اولین مسابقه‌ی Kaggle شما

- همین مسئله‌ی تایتانیک، مسابقه‌ی شروع (Getting Started) سایت Kaggle است
- پیش‌بینی مدل خود را روی داده‌ی تست بسازید، فایل Submission را ارسال کنید و رتبه‌ی جهانی بگیرید!
- kaggle.com/c/titanic
- چالش هفته: با تغییر ویژگی‌ها و ابرپارامترها، دقت بالای ۸۰٪ بگیرید

مفهوم پیشرفته‌تر: جنگل تصادفی (Random Forest)

- یک درخت ممکن است اشتباه کند؛ اما «جمع عقل» صدها درخت، به ندرت!
- صدها درخت می‌سازیم که هر کدام بخشی از داده‌ها و ویژگی‌ها را می‌بینند
- پیش‌بینی نهایی با رای‌گیری بین درخت‌ها تعیین می‌شود؛ خطاهای تصادفی یکدیگر را خنثی می‌کنند
- جنگل تصادفی سال‌ها پادشاه مسابقات Kaggle روی داده‌های جدولی بود، در نوت‌بوک امتحانش کنید!
- جلسه‌ی بعد: کوه‌نورد برمی‌گردد! دسته‌بندی با گرادیان کاهشی، به سوی شبکه‌های عصبی